نام دانشجو :

محراب عتیقی

نام استاد :

دکتر امیر تیمور پاینده نجف آبادی

موضوع :

تحلیل دیتا صدور و خسارت رشته ثالث یک شرکت بیمه به کمک الگوریتم های یادگیری ماشین و شبکه‌های عصبی

نام درس :

تحلیل های بیم سنجی مبتنی بر ابرداده

زمستان 1403

داشنگاه شهید بهشتی

دانشکده علوم ریاضی

فهرست مطالب

چکیده

در این پروژه، هدف اصلی تحلیل داده‌های صدور و خسارت رشته ثالث یک شرکت بیمه با استفاده از الگوریتم‌های هوش مصنوعی است. داده‌های مورد استفاده شامل اطلاعات مربوط به مشتریان، انواع بیمه‌نامه‌های صادر شده، میزان حق بیمه، تاریخچه خسارت‌ها، میزان پرداختی‌ها و سایر متغیرهای مرتبط بود. با استفاده از روش‌های پیشرفته تحلیل داده و الگوریتم‌های هوش مصنوعی، سعی شد تا متغیر های معنا دار بر خسارت شناسایی شده و از این اطلاعات برای بهبود تصمیم‌گیری‌های شرکت بیمه استفاده شود.

الگوریتم‌های هوش مصنوعی نقش حیاتی در تجزیه و تحلیل داده‌ها ایفا می‌کنند، زیرا توانایی پردازش حجم عظیمی از اطلاعات را دارند و الگوهای پیچیده و پنهان را کشف می‌کنند. در پروژه تحلیل داده‌های صدور و خسارت شرکت بیمه، این الگوریتم‌ها با پیش‌بینی دقیق خسارت‌ها و شناسایی مشتریان پرریسک، به شرکت کمک کردند تا ریسک‌های مالی را کاهش داده و تصمیم‌گیری‌های بهینه‌تری داشته باشند. به‌عنوان مثال، مدل‌هایی مانند جنگل تصادفی و شبکه‌های عصبی با تحلیل داده‌های تاریخی، بینش‌هایی ارائه دادند که بهبود فرآیندهای صدور بیمه و مدیریت خسارت را ممکن ساخت.

اهمیت الگوریتم‌های هوش مصنوعی در این است که آن‌ها نه‌تنها دقت تحلیل‌ها را افزایش می‌دهند، بلکه سرعت و کارایی فرآیندها را نیز بهبود می‌بخشند. با استفاده از این فناوری‌ها، شرکت‌های بیمه می‌توانند به‌طور خودکار داده‌ها را تحلیل کرده و در زمان واقعی به تغییرات واکنش نشان دهند. این امر منجر به کاهش هزینه‌ها، افزایش سودآوری و ارائه خدمات بهتر به مشتریان می‌شود. در نهایت، هوش مصنوعی به‌عنوان یک ابزار استراتژیک، شرکت‌ها را قادر می‌سازد تا در محیط رقابتی امروز، عملکرد خود را به‌طور چشمگیری بهبود بخشند.

اهداف

هدف اصلی این پروژه، پیش‌بینی احتمال وقوع خسارت برای بیمه‌گذاران بر اساس مشخصات و داده‌های تاریخی آن‌ها است. با استفاده از الگوریتم‌های هوش مصنوعی و یادگیری ماشین، مدلی طراحی می‌شود که بتواند با دقت بالا تشخیص دهد آیا یک بیمه‌گذار با ویژگی‌های خاص در آینده به خسارت دچار می‌شود یا خیر. خروجی این مدل به صورت باینری (1 به معنای وقوع خسارت و 0 به معنای عدم وقوع خسارت) خواهد بود. این پیش‌بینی به شرکت بیمه کمک می‌کند تا ریسک‌های مالی خود را بهتر مدیریت کرده و سیاست‌های بیمه‌ای را به‌طور هدفمند تنظیم کند.

در راستای این هدف، تحلیل داده‌های تاریخی شرکت بیمه و شناسایی متغیرهای مؤثر بر وقوع خسارت نیز انجام می‌شود. این تحلیل‌ها به درک بهتر عوامل ریسک و بهبود دقت مدل پیش‌بینی کمک می‌کنند. در نهایت، این پروژه به دنبال ارائه یک ابزار تصمیم‌گیری هوشمند است که بتواند به شرکت بیمه در کاهش هزینه‌های ناشی از خسارت‌های غیرمنتظره و افزایش سودآوری کمک کند.

علاوه بر پیش‌بینی وقوع خسارت، این پروژه به دنبال ایجاد یک سیستم طبقه‌بندی هوشمند است که بتواند به‌طور خودکار بیمه‌گذاران را در دو دسته‌ی "با ریسک خسارت" و "بدون ریسک خسارت" دسته‌بندی کند. این سیستم با استفاده از الگوریتم‌های پیشرفته‌ی یادگیری ماشین، مانند درخت تصمیم، جنگل تصادفی و شبکه‌های عصبی، طراحی می‌شود تا بتواند با دقت بالا و بر اساس داده‌های واقعی، پیش‌بینی‌های قابل اعتمادی ارائه دهد. این قابلیت به شرکت بیمه امکان می‌دهد تا منابع خود را به‌طور مؤثرتری تخصیص داده، از مشتریان پرریسک به‌طور ویژه مراقبت کند و در نهایت، از زیان‌های مالی غیرمنتظره جلوگیری نماید. این رویکرد نه‌تنها به بهبود عملکرد مالی شرکت کمک می‌کند، بلکه تجربه‌ی بهتری را نیز برای مشتریان به ارمغان می‌آورد.

واژگان کلیدی

- ✓ پیش‌بینی خسارت
- ✓ الگوریتم‌های هوش مصنوعی
- ✓ یادگیری ماشین
- ✓ طبقه‌بندی باینری (1 و ۰)
- ✓ بیمه‌گذاران پرریسک
- ✓ تحلیل داده‌های تاریخی
- ✓ مدیریت ریسک مالی
- ✓ درخت تصمیم
- ✓ جنگل تصادفی (Random Forest)
- ✓ شبکه‌های عصبی
- ✓ کاهش هزینه‌های خسارت
- ✓ بهبود تصمیم‌گیری
- ✓ متغیرهای مؤثر بر خسارت
- ✓ سیستم پیش‌بینی هوشمند
- ✓ بهینه‌سازی سیاست‌های بیمه‌ای

مقدمه

در دنیای امروز، صنعت بیمه با حجم عظیمی از داده‌ها مواجه است که شامل اطلاعات مربوط به بیمه‌گذاران، انواع بیمه‌نامه‌های صادر شده، تاریخچه خسارت‌ها و سایر متغیرهای مرتبط می‌شود. این داده‌ها، اگر به درستی تحلیل شوند، می‌توانند بینش‌های ارزشمندی را در اختیار شرکت‌های بیمه قرار دهند تا بتوانند ریسک‌های مالی خود را بهتر مدیریت کرده و تصمیم‌گیری‌های استراتژیک بهتری اتخاذ کنند. با این حال، تحلیل این حجم از داده‌ها با روش‌های سنتی نه‌تنها زمان‌بر است، بلکه ممکن است نتواند الگوهای پیچیده و پنهان موجود در داده‌ها را به‌طور کامل شناسایی کند. اینجاست که فناوری‌های نوین مانند هوش مصنوعی و یادگیری ماشین به کمک صنعت بیمه می‌آیند.

هدف این پروژه، استفاده از الگوریتم‌های هوش مصنوعی برای پیش‌بینی احتمال وقوع خسارت در بیمه‌گذاران بر اساس مشخصات و داده‌های تاریخی آن‌ها است. به عبارت دیگر، این پروژه به دنبال پاسخ به این سوال است که آیا یک بیمه‌گذار با ویژگی‌های خاص (مانند سن، نوع بیمه‌نامه، سابقه خسارت و ...) در آینده به خسارت دچار می‌شود یا خیر. خروجی این تحلیل به صورت باینری (1 به معنای وقوع خسارت و 0 به معنای عدم وقوع خسارت) خواهد بود. برای دستیابی به این هدف، از الگوریتم‌های پیشرفته‌ی یادگیری ماشین مانند درخت تصمیم، جنگل تصادفی و شبکه‌های عصبی استفاده می‌شود تا مدلی طراحی شود که بتواند با دقت بالا، بیمه‌گذاران پرریسک را شناسایی کند.

این پروژه نه‌تنها به شرکت بیمه کمک می‌کند تا ریسک‌های مالی خود را کاهش دهد، بلکه با ارائه‌ی یک سیستم پیش‌بینی هوشمند، امکان بهینه‌سازی فرآیندهای صدور بیمه‌نامه و مدیریت خسارت را نیز فراهم می‌آورد. در نهایت، این رویکرد منجر به کاهش هزینه‌های ناشی از خسارت‌های غیرمنتظره، افزایش سودآوری و بهبود تجربه‌ی مشتریان خواهد شد. با توجه به اهمیت روزافزون داده‌ها در صنعت بیمه، این پروژه

گامی مؤثر در جهت تحول دیجیتال و استفاده از فناوری‌های نوین برای بهبود عملکرد سازمانی محسوب می‌شود.

تعاریف

تعاریف مدل‌های یادگیری ماشین:

- **GLM (Generalized Linear Model)**

مدل‌های خطی تعمیم‌یافته (GLM) یک خانواده از مدل‌های آماری هستند که برای تحلیل داده‌هایی استفاده می‌شوند که رابطه‌ی بین متغیرهای مستقل و وابسته ممکن است خطی نباشد. این مدل‌ها می‌توانند برای مسائل رگرسیون و طبقه‌بندی استفاده شوند و از توزیع‌های مختلفی مانند نرمال، دوجمله‌ای و پواسون پشتیبانی می‌کنند.

- **GLMNET (Generalized Linear Model with Regularization)**

این مدل نسخه‌ای از مدل‌های خطی تعمیم‌یافته است که از تکنیک‌های regularizationمانند لاسو و ریج برای جلوگیری از بیش‌برازش (overfitting)استفاده می‌کند. این مدل به‌ویژه برای داده‌هایی با تعداد متغیرهای زیاد (high-dimensional data) مناسب است.

- **RPART (Recursive Partitioning and Regression Trees)**

این مدل یک الگوریتم درخت تصمیم است که برای مسائل رگرسیون و طبقه‌بندی استفاده می‌شود. این مدل با تقسیم‌بندی بازگشتی داده‌ها به زیرمجموعه‌های همگن، یک درخت تصمیم ایجاد می‌کند. این روش ساده و تفسیرپذیر است اما ممکن است به بیش‌برازش منجر شود.

- **RF (Random Forest)**

جنگل تصادفی (Random Forest) یک الگوریتم یادگیری مجموعه‌ای (ensemble learning)است که از ترکیب چندین درخت تصمیم ساخته می‌شود. هر درخت بر روی یک نمونه‌ی bootstrap از داده‌ها آموزش می‌بیند و پیش‌بینی نهایی بر اساس میانگین یا رأی اکثریت درخت‌ها انجام می‌شود. این مدل به‌دلیل دقت بالا و مقاومت در برابر بیش‌برازش، بسیار محبوب است.

- GBM (Gradient Boosting Machine)

ماشین افزایش گرادیان (GBM) یک الگوریتم یادگیری مجموعه‌ای است که از ترکیب چندین مدل ضعیف (معمولاً درخت‌های تصمیم) برای ایجاد یک مدل قوی استفاده می‌کند. این مدل به‌صورت تدریجی و با کاهش خطا (گرادیان) آموزش می‌بیند و برای مسائل رگرسیون و طبقه‌بندی کاربرد دارد.

- XGBTREE (Extreme Gradient Boosting Trees)

مدلXGBoost یک نسخه‌ی بهینه‌شده و پیشرفته از الگوریتم Gradient Boostingاست که از درخت‌های تصمیم استفاده می‌کند. این مدل به‌دلیل سرعت بالا، دقت و قابلیت مدیریت داده‌های بزرگ، بسیار مورد توجه قرار گرفته است XGBoost .از regularization و تکنیک‌های دیگری برای بهبود عملکرد استفاده می‌کند.

- SVMRADIAL (Support Vector Machine with Radial Kernel)

ماشین بردار پشتیبان (SVM) با کرنل شعاعی (Radial Kernel) یک الگوریتم قدرتمند برای مسائل طبقه‌بندی و رگرسیون است. این مدل با استفاده از توابع کرنل، داده‌ها را به فضای با ابعاد بالاتر منتقل می‌کند تا بتواند مرزهای

تصمیم‌گیری غیرخطی ایجاد کند. کرنل شعاعی یکی از پرکاربردترین کرنل‌ها در SVMاست.

- KNN (K-Nearest Neighbors)

الگوریتم K-نزدیک‌ترین همسایه (KNN) یک روش ساده و غیرپارامتری برای طبقه‌بندی و رگرسیون است. این مدل بر اساس فاصله‌ی بین نقاط داده، پیش‌بینی را انجام می‌دهد. برای یک نقطه‌ی جدید، Kنزدیک‌ترین همسایه‌ها شناسایی می‌شوند و برچسب کلاس یا مقدار پیش‌بینی شده بر اساس آن‌ها تعیین می‌شود.

- PLS (Partial Least Squares)

حداقل مربعات جزئی (PLS) یک روش کاهش ابعاد است که برای مسائل رگرسیون و طبقه‌بندی استفاده می‌شود. این مدل با پیدا کردن جهت‌هایی در فضای متغیرهای مستقل که بیشترین همبستگی را با متغیر وابسته دارند، داده‌ها را به ابعاد کم‌تر کاهش می‌دهد .PLS به‌ویژه برای داده‌هایی با تعداد متغیرهای زیاد و هم‌خطی (multicollinearity) مناسب است.

- NNET (Neural Network)

شبکه‌های عصبی مصنوعی (NNET) مدل‌هایی هستند که از ساختار مغز انسان الهام گرفته‌اند و از لایه‌های متعدد نورون‌ها تشکیل شده‌اند. این مدل‌ها می‌توانند روابط غیرخطی پیچیده را در داده‌ها یاد بگیرند و برای مسائل طبقه‌بندی و رگرسیون استفاده می‌شوند. شبکه‌های عصبی به‌دلیل انعطاف‌پذیری و قدرت بالا، در بسیاری از کاربردهای یادگیری ماشین مورد استفاده قرار می‌گیرند.

این مدل‌ها هر کدام مزایا و معایب خاص خود را دارند و انتخاب آن‌ها به نوع مسئله، حجم داده‌ها و اهداف پروژه بستگی دارد.

مراحل انجام پروژه

1- جمع‌آوری و پیش‌پردازش داده‌ها:

- داده‌ها شامل اطلاعات ساختاریافته و غیرساختاریافته بودند که نیاز به پاک‌سازی، یکپارچه‌سازی و تبدیل به فرمت مناسب برای تحلیل داشتند.

- عملیات پیش‌پردازش شامل حذف داده‌های تکراری، پر کردن مقادیر (Missing Values)، نرمال‌سازی داده‌ها و کدگذاری متغیرهای کیفی انجام شد.

2- تحلیل اکتشافی داده‌ها(EDA) :

- با استفاده از روش‌های آماری و مصورسازی داده‌ها، توزیع متغیرها، همبستگی بین آن‌ها و الگوهای اولیه شناسایی شد.

- این مرحله به درک بهتر داده‌ها و شناسایی متغیرهای کلیدی کمک کرد.

3- مدل‌سازی با الگوریتم‌های هوش مصنوعی:

- از الگوریتم‌های مختلف یادگیری ماشین مانند رگرسیون خطی، درخت تصمیم، جنگل تصادفی(Random Forest) ، ماشین بردار پشتیبان (SVM) و شبکه‌های عصبی استفاده شد.

- مدل‌ها برای پیش‌بینی میزان خسارت، شناسایی مشتریان پرریسک و پیش‌بینی احتمال وقوع خسارت آموزش داده شدند.

- از روش‌های ارزیابی مانند دقت(Accuracy) ، دقت طبقه‌بندی(Precision) ، بازیابی (Recall) و F1-Score برای ارزیابی عملکرد مدل‌ها استفاده شد.

4- بهینه‌سازی و تنظیم مدل‌ها:

- با استفاده از تکنیک‌هایی مانند جستجوی شبکه‌ای (Grid Search) و جستجوی تصادفی(Random Search) ، پارامترهای مدل‌ها بهینه‌سازی شدند.

- از روش‌های کاهش ابعاد مانندPCA (تحلیل مؤلفه‌های اصلی) برای بهبود عملکرد مدل‌ها استفاده شد.

5- تحلیل نتایج و ارائه پیشنهادات:

- نتایج نشان داد که برخی از متغیرها تأثیر قابل توجهی بر میزان خسارت دارند.

- مدل‌های پیش‌بینی کننده با دقت قابل قبولی قادر به پیش‌بینی میزان خسارت و شناسایی مشتریان پرریسک بودند.

- بر اساس نتایج، پیشنهاداتی برای بهبود فرآیندهای صدور بیمه‌نامه و مدیریت خسارت ارائه شد.

معرفی داده ها

دیتا استخراج شده از بورد رو صدور و خسارت سیستم بیمه گری شامل 20 اکسل صدور و 3 اکسل خسارت می باشد.

تعداد داده های خسارت شامل 2,193,922 مشاهده است.که به عنوان نمونه یکی از دیتاهای صدور شامل متغیر های زیر است:

ردیف	نام کاربر ثبت کننده بیمه نامه	سابقه سرنشین
شعبه سرپرست واحد صدور بیمه نامه	شماره کامل	سابقه مالی / جانی
استان شعبه سرپرست واحد صدور بیمه نامه	کد پرسنلی	حق بیمه ثالث اجباری
سرپرست واحد صدور بیمه نامه	نوع بیمه گذار	حق بیمه تعدد دیات
واحد صدور بیمه نامه	شرکت بیمه سال قبل	حق بیمه مازاد جانی
استان واحد صدور بیمه نامه	شماره بیمه سال قبل	حق بیمه مازاد مالی
تاریخ صدور	پلاک	حق بیمه حوادث راننده
نام بیمه گذار	شماره موتور	حق بیمه صندوق
کد یونیک بیمه گذار	شماره شاسی	حق بیمه پایه
منطقه آموزش و پرورش بیمه گذار	سال ساخت خودرو (شمسی)	عوارض بهداشت
بازاریاب	سیستم خودرو	عوارض ردیف 160111 قانون بودجه
نوع خودرو	نوع پلاک	حق بیمه صندوق (سهم بیمه مرکزی)
گروه خودرو	سری چاپ	مالیات ارزش افزوده
دسته بندی خودرو	سریال چاپ	عوارض ارزش افزوده
مورد استفاده خودرو	شماره بایگانی قرارداد	حق بیمه صندوق (سهم بیمه گر)
تاریخ شروع	شماره قرارداد	خالص حق بیمه
مدت (روز)	کد رایانه قرارداد	خالص حق بیمه + مالیات و عوارض ارزش افزوده
تاریخ پایان	پوشش جانی (میلیون ریال)	خالص حق بیمه – حق بیمه صندوق + مالیات و عوارض ارزش افزوده
کد رایانه	پوشش مالی(میلیون ریال)	
استان سرپرست واحد صدور بیمه نامه	پوشش حوادث راننده(میلیون ریال)	

دیتا های خسارت شامل 3 فایل اکسل می باشد:

1- خسارت جانی

2- خسارت مالی

3- خسارت سرنشین

تعداد داده های خسارت شامل 80,157 رکورد است که به عنوان نمونه دیتا خسارت سرنشین شامل متغیر های زیر است:

ردیف	شماره بایگانی قرارداد	تعهدجانی(میلیون ریال)
واحد معرف بیمه نامه / الحاقیه	شماره قرارداد بیمه نامه / الحاقیه	تعهدمالی(میلیون ریال)
نام بیمه گذار	نوع بیمه گذار	تعهد حوادث راننده (میلیون ریال)
کد یونیک بیمه گذار	شماره پرونده	نوع خسارت
گروه خودرو	سال ساخت خودرو	واحد سرپرستی بیمه نامه / الحاقیه
واحد صدور حواله	پلاک	آخرین وضعیت پرونده خسارت
سرپرست واحد صدور حواله	تاریخ تشکیل پرونده	مبلغ حواله ثالث اجباری پرداختنی
دسته بندی خودرو	کد رایانه خودرو	مبلغ حواله ثالث اجباری دریافتنی
بابت حواله	تاریخ حادثه	مبلغ حواله ثالث اجباری
واحد تشکیل پرونده	تاریخ اعلام	مبلغ حواله مازاد پرداختنی
سرپرست واحد تشکیل پرونده	کد رایانه پرونده	مبلغ حواله مازاد دریافتنی
نوع خودرو	کاربر ثبت کننده حواله	مبلغ حواله مازاد
تاریخ صدورحواله	نوع گواهینامه مقصر	مبلغ کل حواله
نوع حواله	شماره حواله	کل مبلغ حواله پرداختنی
واحد صدور بیمه نامه/الحاقیه	سابقه مالی	کل مبلغ حواله دریافتنی
تاریخ شروع	سابقه جانی	
شماره بیمه نامه	سابقه حوادث راننده	
تاریخ صدور بیمه نامه	مورد استفاده در زمان صدور بیمه نامه	
تاریخ پایان	مورد استفاده در زمان حادثه	
کد رایانه بیمه نامه	علت حادثه	

تحلیل ، بررسی و مدل سازی دیتا ها در نرم افزار R صورت گرفت که در ادامه به بررسی کد های زده شده در R می پردازیم:

تحلیل و تفسیر کد ها

```
library(dplyr)
```

```
##
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
##
##     filter, lag
```

```
## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union
```

```
library(readxl)
library(ggplot2)
library(DBI)
library(tidyverse)
```

```
## ── Attaching core tidyverse packages ──────────────────────── tidyverse
2.0.0 ──
## ✓ forcats   1.0.0     ✓ stringr   1.5.1
## ✓ lubridate 1.9.4     ✓ tibble    3.2.1
## ✓ purrr     1.0.2     ✓ tidyr     1.3.1
## ✓ readr     2.1.5
```

```
## ── Conflicts ────────────────────────────────────────
tidyverse_conflicts() ──
## ✖ dplyr::filter() masks stats::filter()
## ✖ dplyr::lag()    masks stats::lag()
## ℹ Use the conflicted package (<http://conflicted.r-lib.org/>) to force all
conflicts to become errors
```

```
library(data.table)
```

```
##
## Attaching package: 'data.table'
##
## The following objects are masked from 'package:lubridate':
##
##     hour, isoweek, mday, minute, month, quarter, second, wday, week,
##     yday, year
##
## The following object is masked from 'package:purrr':
```

```
##
##     transpose
##
## The following objects are masked from 'package:dplyr':
##
##     between, first, last
```

```
library(caret)       # For machine learning
```

```
## Loading required package: lattice
##
## Attaching package: 'caret'
##
## The following object is masked from 'package:purrr':
##
##     lift
```

```
library(tensorflow)  # For TensorFlow backend
```

```
##
## Attaching package: 'tensorflow'
##
## The following object is masked from 'package:caret':
##
##     train
```

```
library(keras)       # For neural networks
library(doParallel)
```

```
## Loading required package: foreach
##
## Attaching package: 'foreach'
##
## The following objects are masked from 'package:purrr':
##
##     accumulate, when
##
## Loading required package: iterators
## Loading required package: parallel
```

ابتدا به فراخوانی پکیج های مورد نیاز پرداخته شد.

```
############################################################ Policy Data
Cleaning
##read all policies excel files with .xlsx pattern.

file.list = list.files( pattern='*.xlsx' , recursive = TRUE )
policies <- lapply(file.list[4:33], read_excel)
#
# # bind each files with row
all_policies_df = bind_rows(policies)
```

```r
#remove some columns manualy

df_sodor  = as.data.table(
  all_policies_df[,-c(1,2,3,4,10,19,20,23,26,28,29,33,34,35,36,37)]
  )

df_sodor =
  df_sodor %>%
  separate(col = `مالی سابقه / جانی`, into = c("c1",
"FinanceHistory","LifeHistory"), sep = ":", remove = T)
df_sodor = df_sodor[,-c(which(names(df_sodor) == "c1"))]
df_sodor$FinanceHistory = substr(df_sodor$FinanceHistory ,
                                          start = 1, stop =
nchar(df_sodor$FinanceHistory)-6)
df_sodor= as.data.table(df_sodor)
# save(df_sodor , file = "policies_list.RData")
# load("policies_list.RData")
#find columns with low or very high variance to delete them

# ستون 40 با نمونه فریم‌داده یک ایجاد categorical
set.seed(123)
coded_dfs <- list()
categorical_columns <- names(which(
  sapply(df_sodor, is.factor) | sapply(df_sodor, is.character) == T))
# جداگانه فریم‌داده ایجاد و ستون هر به کددهی برای حلقه
for (col in categorical_columns) {
  # کد ستون ایجاد
  df_sodor[, paste0(col, "_Code") := as.numeric(factor(get(col)))]

  # ستون این برای جداگانه فریم‌داده ایجاد
  coded_dfs[[col]] <- df_sodor[, .(get(col), get(paste0(col, "_Code")))]
  coded_dfs[[col]] <- unique(df_sodor[, .(get(col), get(paste0(col,
"_Code")))])
  names(coded_dfs[[col]]) <- c(col, paste0(col, "_Code"))
}

# save(coded_dfs , file = "coded_dfs.RData")
# load("coded_dfs.RData")
df_sodor = as.data.frame(df_sodor)
df_with_coding = df_sodor[,which(names(df_sodor) %notin%
categorical_columns)]

# remove some linearity columns mannulay for example A+B-C = D
df_with_coding = df_with_coding[,-c(21,22)]
names(df_with_coding)
```

```
##  [1] "گذار بیمه یونیک کد"                  "(روز) مدت"
##  [3] "(شمسی) خودرو ساخت سال"               "(ریال میلیون) جانی پوشش"
##  [5] "(ریال میلیون)مالی پوشش"              "(ریال میلیون)راننده حوادث پوشش"
##  [7] "اجباری ثالث بیمه حق"                 "دیات تعدد بیمه حق"
##  [9] "جانی مازاد بیمه حق"                  "مالی مازاد بیمه حق"
## [11] "راننده حوادث بیمه حق"                "صندوق بیمه حق"
## [13] "پایه بیمه حق"                        "بهداشت عوارض"
## [15] "بودجه قانون 160111 ردیف عوارض"       "(مرکزی بیمه سهم) صندوق بیمه حق"
## [17] "افزوده ارزش مالیات"                  "افزوده ارزش عوارض"
## [19] "(گر بیمه سهم) صندوق بیمه حق"         "بیمه حق خالص"
## [21] "نامه بیمه صدور واحد_Code"            "نامه بیمه صدور واحد استان_Code"
## [23] "صدور تاریخ_Code"                     "گذار بیمه نام_Code"
## [25] "بازاریاب_Code"                       "خودرو نوع_Code"
## [27] "خودرو گروه_Code"                     "خودرو بندی دسته_Code"
## [29] "خودرو استفاده مورد_Code"             "شروع تاریخ_Code"
## [31] "پایان تاریخ_Code"                    "نامه بیمه کننده ثبت کاربر نام_Code"
## [33] "کامل شماره_Code"                     "گذار بیمه نوع_Code"
## [35] "قبل سال بیمه شرکت_Code"              "پلاک_Code"
## [37] "خودرو سیستم_Code"                    "پلاک نوع_Code"
## [39] "سرنشین سابقه_Code"                   "FinanceHistory_Code"
## [41] "LifeHistory_Code"
```

```r
names(df_with_coding) = c("PolicyHolderCode" ,
                          "Duration",
                          "CarProductYear",
                          "SideCover_MR",
                          "FinanceCover_MR",
                          "AccidentCover_MR",
                          "ThirdParty_Pr",
                          "MultipleBloodMoney_Pr",
                          "ExcessLife_Pr",
                          "ExcessFinance_Pr",
                          "DriverAccident_Pr",
                          "Pension_Pr",
                          "Basis_Pr",
                          "Health_Complications",
                          "Goverment_Complications",
                          "CentralInsurance_Pension_Pr",
                          "ValueAdded_Tax",
                          "ValueAdded_Complications",
                          "Insurer_Pension_Pr",
                          "Net_Pr",
                          "ID_PolicyLuncher_Departmant",
                          "ID_PolicyLuncher_Province",
                          "ID_LunchDate",
                          "ID_PolicyHolderName",
                          "ID_MarkettingBy",
                          "ID_AutomobileType",
                          "ID_AutomobileGroup",
                          "ID_AutomobileClass",
```

```
                          "ID_AutomobuileUssage",
                          "ID_StartDate",
                          "ID_EndDate",
                          "ID_RegisterUser",
                          "ID_Policy",
                          "ID_PolicyHolderType",
                          "ID_LastInsurer",
                          "ID_AutomobileZipCode",
                          "ID_AutomobileSystem",
                          "ID_AutomobileZipCodeType",
                          "ID_Passengers_Claim",
                          "ID_Finance_Claim",
                          "ID_Life_Claim"
                          )
# save(df_with_coding , file = "df_with_coding.RData")
# load("df_with_coding.RData")
```

در این کدها، یک فرآیند پاک‌سازی و آماده‌سازی داده‌های مربوط به بیمه‌نامه‌ها (Policy Data) صورت گرفت. مراحل اصلی به شرح زیر است:

1- خواندن داده‌ها :

- **تمام فایل‌های اکسل با پسوند `.xlsx` که حاوی داده‌های بیمه‌نامه‌ها بودند، خوانده شدند و در یک لیست ذخیره شدند.**
- **سپس این فایل‌ها به یک داده‌فریم واحد (`all_policies_df`) تبدیل شدند.**

2- حذف ستون‌های غیرضروری:

- **برخی ستون‌ها که مورد نیاز نبودند، به صورت دستی حذف شدند.**

3- تجزیه و اصلاح داده‌ها:

- **ستون `سابقه مالی / جانی` به دو ستون جداگانه (`FinanceHistory` و `LifeHistory`) تقسیم شد و بخش‌های اضافی از این ستون‌ها حذف شدند.**

4- کدگذاری داده‌های کیفی:

- ستون‌های کیفی (کاراکتر یا فاکتور) شناسایی و به صورت عددی کدگذاری شدند.

- برای هر ستون کیفی، یک ستون جدید با پسوند `_Code` ایجاد شد که حاوی کدهای عددی مربوطه بود.

5- حذف ستون‌های با واریانس کم یا زیاد:

- ستون‌هایی که دارای واریانس کم یا زیاد بودند و یا باعث ایجاد خطی‌بودن (linearity)می‌شدند، حذف شدند.

6- تغییر نام ستون‌ها:

- نام ستون‌ها به انگلیسی تغییر داده شد تا خوانایی و یکپارچگی داده‌ها بهبود یابد.

7- ذخیره‌سازی داده‌ها:

- داده‌های نهایی در قالب فایل‌های `.RData` ذخیره شدند تا در مراحل بعدی تحلیل مورد استفاده قرار گیرند.

در نهایت، یک داده‌فریم تمیز و آماده برای تحلیل‌های بعدی ایجاد کردید که شامل داده‌های عددی و کدگذاری‌شده است. این داده‌ها می‌توانند برای آموزش مدل‌های یادگیری ماشین و پیش‌بینی خسارت استفاده شوند.

```r
##########################################################Claim Data Cleaning
file.list = list.files( pattern='*.xlsx' , recursive = TRUE )
 Claims <- lapply(file.list[1:3], read_excel)
  names(Claims[[1]])[54] = "LifeLoss_Value"
  names(Claims[[2]])[54] = "PassengerLoss_Value"
  names(Claims[[3]])[54] = "FinanceLoss_Value"

# bind each files with row
 all_claims_df = bind_rows(Claims)

#remove some columns manualy

 df_claims  = as.data.table(
   all_claims_df[,c(17,54,56,57)]
   )
 df_claims = as.data.frame(df_claims)
names(df_claims)[1] = c("ID_Policy")
for(i in 2:4){
  df_claims[,i] = ifelse(is.na(df_claims[,i]) , 0  , df_claims[,i])
}

########################################################## Merging Data
library(dplyr)
library(readxl)
library(ggplot2)
library(DBI)
library(tidyverse)
library(data.table)

# load("df_with_coding.RData")
# load("Claims_list.RData")
# load("coded_dfs.RData")
names(coded_dfs[["کامل شماره"]])[1] = "ID_Policy"
# coded_dfs[["کامل شماره"]]$ID_Policy = as.character(coded_dfs[["شماره
کامل"]]$ID_Policy)
claims_with_code = left_join(df_claims , coded_dfs[["کامل شماره"]] , by =
"ID_Policy",keep = F )
claims_with_code = claims_with_code[,-c(1)] #remove ID_Ploicy column
names(claims_with_code)[4] = "ID_Policy"
FinalDf = left_join(df_with_coding , claims_with_code , by = "ID_Policy")
# save(FinalDf , file = "FinalDf.RData")
```

در این کد مراحل زیر صورت گرفته است:

1- خواندن فایل‌ها:

- فایل‌های اکسل با پسوند `xlsx.` از دایرکتوری جاری و زیردایرکتوری‌ها خوانده شده‌اند.

- سه فایل اول به لیست `Claims` اضافه شده‌اند.

2- تغییر نام ستون‌ها:

- ستون 54 در هر یک از سه فایل به ترتیب به`LifeLoss_Value` ، `PassengerLoss_Value`و `FinanceLoss_Value` تغییر نام داده شده است.

3- ادغام داده‌ها:

- داده‌های سه فایل به صورت سطری (row-wise) با هم ادغام شده‌اند و در `all_claims_df`ذخیره شده‌اند.

4- حذف ستون‌ها:

- تنها ستون‌های 17، 54، 56 و 57 از داده‌های ادغام‌شده انتخاب شده‌اند و در `df_claims`ذخیره شده‌اند.

- نام ستون اول به `ID_Policy` تغییر یافته است.

- مقادیر `NA` در ستون‌های 2 تا 4 با صفر جایگزین شده‌اند.

5- ادغام با داده‌های کدگذاری‌شده:

- داده‌های `df_claims` با داده‌های کدگذاری‌شده"(`coded_dfs`) شماره کامل بر اساس ستون `ID_Policy` ادغام شده‌اند.

- ستون `ID_Policy` از داده‌های ادغام‌شده حذف شده و نام ستون چهارم به `ID_Policy`تغییر یافته است.

6- ادغام نهایی:

- داده‌های `df_with_coding` با داده‌های ادغام‌شده (`claims_with_code`) بر اساس `ID_Policy` ادغام شده‌اند و نتیجه در `FinalDf` ذخیره شده است.

```
############################################################ CV Modeling
# cl <- makePSOCKcluster(4)  # تعداد هسته‌های پردازنده (مثلاً 4)
# registerDoParallel(cl)
#load("FinalDf.RData")
for(i in 42:44){
  FinalDf[,i] = ifelse(is.na(FinalDf[,i]) , 0  , FinalDf[,i])
}
FinalDf$HaveLoss =
  ifelse(FinalDf$LifeLoss_Value +
  FinalDf$PassengerLoss_Value +
  FinalDf$FinanceLoss_Value > 0 ,1,0)
FinalDf$HaveLoss = as.factor(FinalDf$HaveLoss)
#remove some columns for na values and other loss types.

# Check for missing values in each column
missing_values <- colSums(is.na(FinalDf))

FinalDf = FinalDf[,-c(42:44)]
FinalDf = FinalDf[,-c(which(colnames(FinalDf) %in%
names(which(missing_values>0 )))))]
split_data <- function(data, train_percentage) {
  # Ensure the train_percentage is between 0 and 1
  if (train_percentage < 0 || train_percentage > 1) {
    stop("train_percentage must be between 0 and 1")
  }
    # Calculate the number of rows for the training set
  n <- nrow(data)
  n_train <- floor(train_percentage * n)

  # Randomly sample the indices for the training set
  train_indices <- sample(1:n, n_train)

  # Create the training and test sets
  train_set <- data[train_indices, ]
  test_set <- data[-train_indices, ]

  # Return the training and test sets as a list
```

```r
  return(list(train = train_set, test = test_set))
}
set.seed(123)
# Assuming finalDf is your dataset and you want 80% for training
result <- split_data(FinalDf, train_percentage = 0.8)
train_set <- result$train
test_set <- result$test

######
dim(train_set)

## [1] 1755137 36

head(train_set)

##     PolicyHolderCode Duration CarProductYear SideCover_MR FinanceCover_MR
## 415         210800.4      365           1377          350              20
## 463         214757.9      365           1382          350              10
## 179         219846.8      365           1383          400              20
## 526         221096.4      365           1364          400              20
## 195         211513.5        4           1380          350              10
## 938         267169.1      365           1384          350              10
##     ThirdParty_Pr MultipleBloodMoney_Pr ExcessLife_Pr ExcessFinance_Pr
## 415        208250                    0        818332           272777
## 463        189000                    0        896898           298966
## 179        169575                    0        981349           327116
## 526        378250                    0       2165756           721919
## 195         12250                    0         58454            19485
## 938        232750                    0       1110609           370203
##     DriverAccident_Pr Pension_Pr Basis_Pr Health_Complications
## 415            119000          0  1702033               141837
## 463             72000          0  1748238               145687
## 179            104500          0  1899050               158255
## 526             93500          0  4031311               335943
## 195              4000          0   113029                 9420
## 938             76000          0  2147476               178957
##     Goverment_Complications CentralInsurance_Pension_Pr ValueAdded_Tax
## 415                       0                           0             0
## 463                       0                           0             0
## 179                       0                           0             0
## 526                       0                           0             0
## 195                       0                           0             0
## 938                       0                           0             0
##     ValueAdded_Complications Insurer_Pension_Pr  Net_Pr
## 415                        0                  0 1560196
## 463                        0                  0 1602551
## 179                        0                  0 1740795
## 526                        0                  0 3695368
## 195                        0                  0  103609
## 938                        0                  0 1968519
```

```
##     ID_PolicyLuncher_Departmant ID_PolicyLuncher_Province ID_LunchDate
## 415                        1114                        8          167
## 463                        1114                        8          167
## 179                         776                       17          149
## 526                        1114                        8          260
## 195                        1163                        8          153
## 938                        1163                        8          403
##     ID_AutomobileType ID_AutomobileGroup ID_AutomobuileUssage ID_StartDate
## 415              4078                  3                    67          189
## 463               969                  3                    67          189
## 179              5088                  2                    47          168
## 526              2981                  2                    19          303
## 195              1038                  3                    57          172
## 938              1069                  3                    67          472
##     ID_EndDate ID_RegisterUser ID_Policy ID_PolicyHolderType
## 415        194             444      1514                   1
## 463        194             444      1557                   1
## 179        173             680      1977                   2
## 526        307             250      5915                   1
## 195          1            2173       787                   1
## 938        476            2262      3582                   2
##     ID_AutomobileZipCode ID_AutomobileZipCodeType ID_Passengers_Claim
## 415                 3539                       10                   2
## 463                 3539                       10                   9
## 179                 2364                       11                  23
## 526                  537                       12                  13
## 195                  660                       10                   4
## 938                  657                       10                  23
##     ID_Finance_Claim ID_Life_Claim HaveLoss
## 415                2             2        0
## 463                9             9        0
## 179               23            23        0
## 526               13            13        0
## 195                4             4        0
## 938               23            23        0
```

این کد یک فرآیند پیش‌پردازش داده‌ها (Data Preprocessing) و تقسیم داده‌ها به دو بخش آموزش (Train) و آزمون (Test) را انجام می‌دهد. در ادامه به طور مختصر مراحل و خروجی‌ها توضیح داده می‌شوند:

مراحل انجام شده:

1- مدیریت مقادیر گم‌شده (NA):

- مقادیر گم‌شده در ستون‌های 42 تا 44 با `0` جایگزین شده‌اند.

2- تعریف متغیر هدف (HaveLoss)

- یک متغیر جدید به نام `HaveLoss` ایجاد شده است که نشان می‌دهد آیا مجموع مقادیر `LifeLoss_Value`، `PassengerLoss_Value` و `FinanceLoss_Value` بزرگ‌تر از صفر است یا خیر.

- اگر مجموع این مقادیر بز رگ‌تر از صفر باشد، `HaveLoss` برابر `1` (دارای ضرر) و در غیر این صورت برابر `0` (بدون ضرر) خواهد بود.

- این متغیر به عنوان یک فاکتور (عامل) در نظر گرفته شده است.

3- حذف ستون‌های با مقادیر گم‌شده:

- ستون‌هایی که دارای مقادیر گم‌شده (NA) هستند، شناسایی و حذف شده‌اند.

4- تقسیم داده‌ها به دو بخش آموزش و آزمون:

- داده‌ها به دو بخش 80 درصد داده آموزشی و 20 درصد داده تست افراز شدند.

داده‌های آموزش شامل 1755137 سطر و 36 ستون است. این بدان معناست که 80٪ از داده‌ها (یعنی 1755137 سطر از 2193922 سطر) برای آموزش مدل استفاده می‌شوند.

در ادامه 6 سطر اول از داده‌های آموزش نمایش داده شده است. هر سطر شامل مقادیر مربوط به 36 ستون است.

- ستون HaveLoss نشان می‌دهد که آیا بیمه‌گذار در این سطر دارای ضرر (`1`) بوده یا خیر (`0`).

```
# Separate features (X) and target (y) for training and testing sets
X_train <- train_set[, -c(18:dim(train_set)[2])]  # All columns except the
last one
y_train <- train_set[, c(dim(train_set)[2])]   # Last column (TotalLoss)

X_test <- test_set[, -c(18:dim(test_set)[2])]    # All columns except the
last one
```

```r
y_test <- test_set[, c(dim(test_set)[2])]     # Last column (TotalLoss)
# Scale/normalize the features
preprocess_params <- preProcess(X_train, method = c("center", "scale"))
X_train_scaled <- predict(preprocess_params, X_train)
X_test_scaled <- predict(preprocess_params, X_test)


X_train_scaled = cbind(X_train_scaled, train_set[,18:32])
X_test_scaled = cbind(X_test_scaled, test_set[,18:32])

train_control <- trainControl(
  method = "cv",  # Cross-validation
  number = 5,     # 5-fold CV
  savePredictions = "final",
  allowParallel = TRUE,
  #verboseIter = TRUE  # Show progress updates

)

# Define a list of models to train
models <- c(
  #"lm",           # Linear Regression
  "glm",          # Logistic Regression
  "glmnet",       # Ridge/Lasso Regression
  "rpart",        # Decision Trees
  "rf",           # Random Forests
  "gbm",          # Gradient Boosting Machines
  "xgbTree",      # XGBoost (Gradient Boosting)
  "svmRadial",    # Support Vector Machines (Radial Kernel)
  "knn",          # k-Nearest Neighbors
  "pls",          # Principal Component Regression
  #"lda",          # Linear Discriminant Analysis
  #"qda",          # Quadratic Discriminant Analysis
  #"naive_bayes", # Naive Bayes
  "nnet"          # Neural Networks
)
```

این کد در R برای پیش‌پردازش داده‌ها، آموزش مدل‌های مختلف یادگیری ماشین و ارزیابی آن‌ها با استفاده از اعتبارسنجی متقابل (Cross-Validation) نوشته شده است. در ادامه به طور خلاصه مراحل انجام شده و تحلیل خروجی‌ها آورده شده است.

مراحل انجام شده:

1- جداسازی متغیر های کمکی و پاسخ

2- نرمال‌سازی داده‌ها:

- داده‌های آموزشی و آزمون با استفاده از روش‌های `center` و `scale` نرمال‌سازی شده‌اند.

3- اضافه کردن ستون‌های ۱۸ تا ۳۲ به داده‌های نرمال‌شده:

- این ستون‌ها پس از نرمال‌سازی به داده‌های آموزشی و آزمون اضافه شده‌اند.

تنظیم پارامترهای اعتبارسنجی متقابل:

- از روش ۵-فولد Cross-Validation برای ارزیابی مدل‌ها استفاده شده است.

4- تعریف مدل‌های یادگیری ماشین:

مدل های آموزشی مورد استفاده شده:

- ✓ **Glm**
- ✓ **Glmnet**
- ✓ **Rpart**
- ✓ **Rf**
- ✓ **Gbm**
- ✓ **Xgbtree**
- ✓ **Svmradial**
- ✓ **Knn**
- ✓ **Pls**
- ✓ **nnet**

تحلیل خروجی:

-اعتبارسنجی متقابل(CV) : با استفاده از ۵-فولدCV ، مدل‌ها بر روی زیرمجموعه‌های مختلف داده‌های آموزشی ارزیابی شده‌اند. این روش به کاهش واریانس و افزایش قابلیت تعمیم مدل کمک می‌کند.

-مدل‌های آموزش‌دیده: هر مدل با توجه به معیارهای ارزیابی (مانند دقت، خطا و ...) بر روی داده‌های آزمون ارزیابی می‌شود. مدل‌هایی مانند Random Forests (rf) و XGBoost (xgbTree)معمولاً عملکرد بهتری در پیش‌بینی دارند.

-نتایج: پس از آموزش مدل‌ها، می‌توان با استفاده از معیارهایی مانند `RMSE` برای رگرسیون یا`Accuracy` برای طبقه‌بندی بهترین مدل را انتخاب کرد.

```
# Train and evaluate all models
results <- list()
test_errors <- data.frame(Model = character(), RMSE = numeric(), R2 =
numeric(), MAE = numeric(), stringsAsFactors = FALSE)

for (model in models) {
  set.seed(123)  # For reproducibility
  print(paste("Training model:", model))

  # Train the model
  fit <- caret::train(
    x = X_train_scaled,  # Features
    y = y_train,         # Target variable
    method = model,      # Model type
    trControl = train_control
  )

  # Store the results
  results[[model]] <- fit

  # Predict on the test set
  predictions <- predict(fit, newdata = X_test_scaled)

  # Calculate test error metrics
  if (is.factor(y_test)) {  # Classification
    cm <- confusionMatrix(predictions, y_test)
    accuracy <- cm$overall["Accuracy"]
    kappa <- cm$overall["Kappa"]
    test_errors <- rbind(test_errors, data.frame(Model = model, Accuracy =
accuracy, Kappa = kappa))
  } else {  # Regression
    rmse <- sqrt(mean((as.numeric(predictions) - as.numeric(y_test))^2))
```

```
    r2 <- cor(as.numeric(predictions), as.numeric(y_test))^2
    mae <- mean(abs(as.numeric(predictions) - as.numeric(y_test)))
    test_errors <- rbind(test_errors, data.frame(Model = model, RMSE = rmse,
R2 = r2, MAE = mae))
  }
}

# Print test errors
print(test_errors)
```

```
##               Model Accuracy        Kappa
## Accuracy        glm    0.840 -0.019108280
## Accuracy1    glmnet    0.845 -0.009771987
## Accuracy2     rpart    0.850  0.000000000
## Accuracy3        rf    0.865  0.158878505
## Accuracy4       gbm    0.835  0.014925373
## Accuracy5   xgbTree    0.850  0.122807018
## Accuracy6 svmRadial    0.850  0.000000000
## Accuracy7       knn    0.845 -0.009771987
## Accuracy8       pls    0.850  0.000000000
## Accuracy9      nnet    0.850  0.000000000
```

هدف اصلی این کد، آموزش مدل‌های مختلف بر روی داده‌های آموزشی و سپس ارزیابی عملکرد آن‌ها بر روی داده‌های تست است. در ادامه، مراحل اصلی کد و خروجی‌ها به طور خلاصه توضیح داده می‌شوند:

مراحل اصلی کد:

1. تعریف لیست‌ها و داده‌ها:

- یک لیست به نام results برای ذخیره نتایج مدل‌ها و یک دیتافریم به نام test_errors برای ذخیره خطاهای تست (مانند RMSE، R2، MAE برای رگرسیون و Accuracy و Kappa برای طبقه‌بندی) تعریف شده است.

2. آموزش مدل‌ها:

- یک حلقه for برای آموزش مدل‌های مختلف اجرا می‌شود. مدل‌هایی که آموزش داده می‌شوند شامل `glm`، `glmnet`، `rpart`، `rf`، `gbm` و xgbTree هستند.

- برای هر مدل، ابتدا مدل بر روی داده‌های آموزشی آموزش داده می شود.

- سپس مدل آموزش‌دیده بر روی داده‌های تست X_test_scaled اعمال می‌شود و پیش‌بینی‌ها انجام می‌گیرد.

3. محاسبه خطاهای تست:

- اگر مسئله طبقه‌بندی باشد (یعنی y_test فاکتور باشد)، دقت (Accuracy) و کاپا (Kappa) محاسبه می‌شود.

- اگر مسئله رگرسیون باشد، خطاهای RMSE، R2 و MAE محاسبه می‌شوند.

4. ذخیره نتایج:

- نتایج هر مدل در لیست results و خطاهای تست در دیتافریم test_errors ذخیره می‌شوند.

5. چاپ خطاهای تست:

- در نهایت، خطاهای تست برای هر مدل چاپ می‌شود.

تفسیر خروجی:

- دقت مدل‌ها (Accuracy): دقت مدل‌ها در طبقه‌بندی داده‌های تست بین 0.835 تا 0.865 متغیر است. مدل rf (Random Forest) با دقت 0.865 بهترین عملکرد را دارد.

- کاپا (Kappa) : مقدار کاپا برای مدل‌ها بین -0.019 تا 0.158 متغیر است. مدل rf با کاپای 0.158 بهترین عملکرد را در این زمینه دارد.

- خطاهای رگرسیون: اگر مسئله رگرسیون بود، خطاهای RMSE، R2 و MAE برای هر مدل محاسبه می‌شد، اما در اینجا فقط نتایج طبقه‌بندی نشان داده شده است.

نتیجه‌گیری:

- مدل **rf (Random Forest)** بهترین عملکرد را در بین مدل‌های آموزش‌دیده دارد، زیرا هم دقت و هم کاپای آن بالاتر از سایر مدل‌ها است.

- مدل‌های دیگر مانند **xgbTree** و **rpart** نیز عملکرد نسبتاً خوبی دارند، اما به پای مدل **rf** نمی‌رسند.

```
# Compare model performance (cross-validation results)
comparison <- resamples(results)
summary(comparison)

##
## Call:
## summary.resamples(object = comparison)
##
## Models: glm, glmnet, rpart, rf, gbm, xgbTree, svmRadial, knn, pls, nnet
## Number of resamples: 5
##
## Accuracy
##              Min. 1st Qu. Median    Mean 3rd Qu.    Max. NA's
## glm       0.84375 0.85000 0.8500 0.85000 0.85000 0.85625    0
## glmnet    0.85000 0.85000 0.8500 0.85125 0.85000 0.85625    0
## rpart     0.82500 0.84375 0.8500 0.84375 0.85000 0.85000    0
## rf        0.84375 0.85625 0.8625 0.85875 0.86250 0.86875    0
## gbm       0.83125 0.85000 0.8625 0.85625 0.86875 0.86875    0
## xgbTree   0.83125 0.85625 0.8625 0.85625 0.86250 0.86875    0
## svmRadial 0.85000 0.85000 0.8500 0.85125 0.85000 0.85625    0
## knn       0.82500 0.83750 0.8375 0.84000 0.85000 0.85000    0
## pls       0.85000 0.85000 0.8500 0.85125 0.85000 0.85625    0
## nnet      0.85000 0.85000 0.8500 0.85125 0.85000 0.85625    0
##
## Kappa
##                  Min.     1st Qu.      Median         Mean    3rd Qu.
## glm       -0.01214575  0.00000000  0.00000000 -0.002429150 0.00000000
## glmnet     0.00000000  0.00000000  0.00000000  0.000000000 0.00000000
## rpart     -0.04477612  0.00000000  0.00000000  0.008524119 0.04214559
## rf         0.09090909  0.14022518  0.17910448  0.180942715 0.20415225
## gbm       -0.03448276  0.05511811  0.14022518  0.107073461 0.17910448
## xgbTree   -0.03448276  0.07221929  0.11877395  0.114395719 0.17910448
## svmRadial  0.00000000  0.00000000  0.00000000  0.000000000 0.00000000
## knn       -0.04477612 -0.03431129 -0.02362205 -0.020541891 0.00000000
## pls        0.00000000  0.00000000  0.00000000  0.000000000 0.00000000
## nnet       0.00000000  0.00000000  0.00000000  0.000000000 0.00000000
##                   Max. NA's
## glm       0.00000000    0
## glmnet    0.00000000    0
## rpart     0.04525112    0
## rf        0.29032258    0
```

```
## gbm        0.19540230    0
## xgbTree    0.23636364    0
## svmRadial 0.00000000    0
## knn        0.00000000    0
## pls        0.00000000    0
## nnet       0.00000000    0

# Visualize model performance
dotplot(comparison)
```

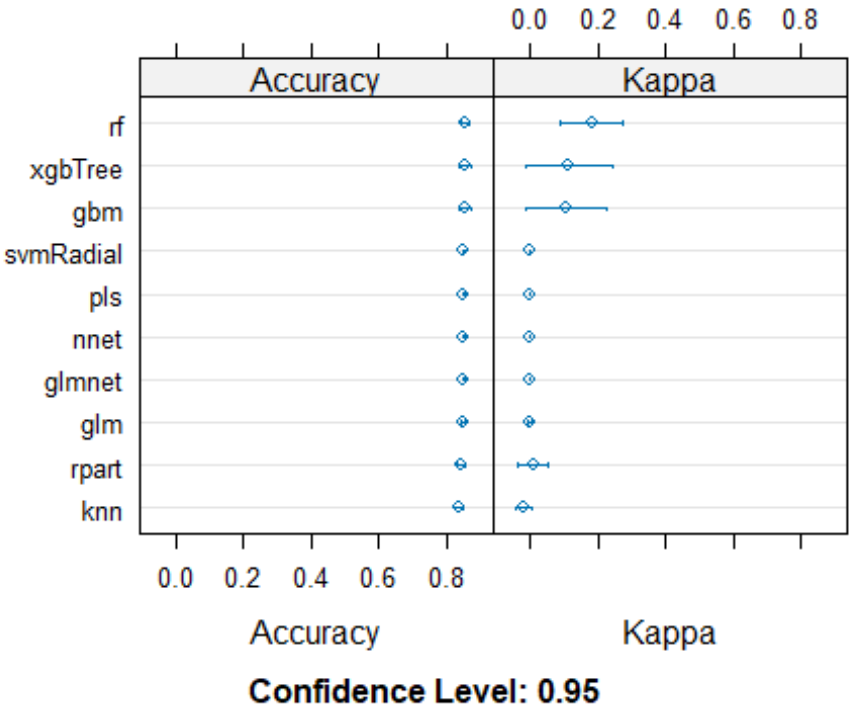

1- مقایسه دقت (Accuracy) مدل‌ها:

- **مدل های rf، gbm و xgbtree بالاترین میانگین دقت را دارند.**
- **مدل های knn و rpart کمترین دقت را دارند.**
- **سایر مدل ها glm، glmnet، nnet، pls، svmradial تقریبا دقت مشابهی دارند.**

2- مقایسه کاپا (شاخص توافق کلاس بندی) مدل ها:

- **Rf بهترین مقدار Kappa را دارد.که نشان‌دهنده توانایی بالاتر آن در پیش‌بینی کلاس‌های درست است.**
- **Gbm و xgbtree نیز عملکرد خوبی دارند.**
- **بقیه مدل ها به خصوص nnet, pls, svmradial, glmnet , glm مقدار کاپا نزدیک به صفر یا حتی منفی دارند، که نشان می‌دهد عملکرد آن‌ها تفاوت زیادی با یک مدل تصادفی ندارد.**

نتیجه‌گیری کلی:

• اگر هدف، بیشترین دقت باشد، مدل‌های rf, gbm, و xgbTree انتخاب‌های بهتری هستند.

• اگر به‌دنبال مدلی هستید که علاوه بر دقت بالا، قابلیت تمایز بهتری بین کلاس‌ها داشته باشد، rfبهترین گزینه است.

• مدل‌های glm, svmRadial, pls, nnet احتمالاً برای این مسئله مناسب نیستند، زیرا مقدار Kappa آن‌ها صفر است، یعنی پیش‌بینی‌های آن‌ها تفاوت خاصی با یک مدل تصادفی ندارد.

یافته‌ها و نتایج

در این پروژه، با استفاده از الگوریتم‌های مختلف یادگیری ماشین، مدل‌هایی برای پیش‌بینی وقوع خسارت بیمه‌ای طراحی و ارزیابی شدند. نتایج نشان داد که مدل‌های Random Forest (rf) , Gradient Boosting Machine (gbm), و XGBoost (xgbTree) از نظر دقت پیش‌بینی، عملکرد بهتری نسبت به سایر مدل‌ها دارند. این مدل‌ها توانستند با دقت بالایی وقوع خسارت را پیش‌بینی کنند، که نشان‌دهنده‌ی قابلیت آن‌ها در یادگیری الگوهای پیچیده از داده‌های تاریخی است. به‌ویژه، مدل Random Forest به دلیل قابلیت تمایز بهتر بین کلاس‌ها، به عنوان بهترین گزینه برای این مسئله شناسایی شد. این مدل نه‌تنها دقت بالایی دارد، بلکه توانایی تشخیص دقیق‌تری بین بیمه‌گذاران پرریسک و کم‌ریسک را نیز فراهم می‌کند.

از سوی دیگر، مدل‌هایی مانند Generalized Linear Model (glm) ، Support Vector Machine with Radial Kernel (svmRadial) ، Partial Least Squares (pls) و Neural Network (nnet) عملکرد ضعیف‌تری داشتند. مقدار Kappa این مدل‌ها صفر بود، که نشان می‌دهد پیش‌بینی‌های آن‌ها تفاوت معناداری با یک مدل تصادفی ندارد. این نتیجه بیانگر آن است که این مدل‌ها برای مسئله‌ی پیش‌بینی وقوع خسارت بیمه‌ای مناسب نیستند و نمی‌توانند الگوهای مؤثر را از داده‌ها استخراج کنند. بنابراین، تمرکز اصلی در این پروژه بر روی مدل‌های rf، gbm و xgbTree قرار گرفت.

در نهایت، این پروژه موفق به طراحی یک سیستم طبقه‌بندی هوشمند شد که می‌تواند بیمه‌گذاران را به‌طور خودکار در دو دسته‌ی "با ریسک خسارت" و "بدون ریسک خسارت" دسته‌بندی کند. این سیستم با استفاده از مدل‌های پیشرفته‌ی یادگیری ماشین، مانند Random Forest و XGBoost، قادر است پیش‌بینی‌های دقیق و قابل اعتمادی ارائه دهد. این قابلیت به شرکت بیمه کمک می‌کند تا منابع خود را به‌طور مؤثرتری مدیریت کرده، از مشتریان پرریسک به‌طور ویژه مراقبت کند و از زیان‌های

مالی غیرمنتظره جلوگیری نماید. این رویکرد نه‌تنها به بهبود عملکرد مالی شرکت کمک می‌کند، بلکه تجربه‌ی بهتری را نیز برای مشتریان به ارمغان می‌آورد.

پایان.